Pesquisa Aplicada à Estatística

Distribuição Amostral

Exemplo Prático.

- Cada aluno deve jogar o dado 3 vezes e calcular a média dos valores das faces.

1. Cada aluno terá uma amostra com 3 valores e uma Média Amostral.
2. A Média Amostral é fixa ou variável?

Por que as Estimativas Variam?

Uma situação real: Dois resultados diferentes

Cenário (laboratório de qualidade):

Dois levantamentos avaliam o tempo médio de processamento de um lote de amostras.

Amostra A	Amostra B
$n = 30$	$n = 30$
$\bar{x}_A = 4,8$ min	$\bar{x}_B = 5,5$ min

- **Pergunta:** Algum levantamento está "errado"?
- **Ideia-chave:** Diferença entre resultados pode ocorrer mesmo quando a coleta é correta.

A causa é a **variabilidade amostral**.

O que varia: população, método ou amostra?

- A **população** de interesse continua a mesma;
- O **método** de estimação permanece o mesmo;
- A **amostra** muda, pois os indivíduos/objetos observados mudam.

Conclusão:

A estimativa muda porque a amostra muda.

IMPORTANTE!!!

Estatísticas variam de amostra para amostra.
Parâmetros são fixos; estimadores é que são variáveis aleatórias.

Vamos Entender Melhor o Processo

Imagine repetir o mesmo estudo Muitas vezes:

1. Coleta-se uma amostra de tamanho n da população
2. Calcula-se a média de cada amostra - $\bar{X}$
3. Guarda-se apenas o valor calculado da média
4. Repete-se o processo

Depois de muitas repetições, surge uma **lista de valores**:

$$\bar{X}_1, \bar{X}_2, \bar{X}_3, \bar{X}_4, \ldots$$

Esses valores formam a distribuição amostral da estatística (MÉDIA).

O que é uma distribuição amostral?

Definition

Uma **distribuição amostral** descreve como uma estatística varia quando amostras diferentes são retiradas da mesma população.

Exemplos:

- Distribuição das **médias amostrais** ($\bar{X}$)
- Distribuição das **proporções amostrais** ($\hat{p}$)
- Distribuição das **variâncias amostrais** (S^2)
- Distribuição das **medianas amostrais**

Atenção: É diferente da distribuição dos *dados individuais*! Aqui estudamos a variabilidade das estimativas, não dos indivíduos/observações.

Por que a média, a proporção amostral e outras ESTATÍSTICAS têm uma distribuição?

- A média amostral ($\bar{X}$) e a proporção amostral ($\hat{p}$) são variáveis aleatórias.
- Cada amostra extraída da população pode ter um valor diferente para $\bar{X}$ e $\hat{p}$.
- A distribuição dessas estatísticas segue um comportamento probabilístico previsível.

Importante

A distribuição amostral descreve como uma estatística varia em diferentes amostras da mesma população.

DISTRIBUIÇÃO AMOSTRAL DA MÉDIA

Exemplo 1:

- População: {2, 3, 4, 5}

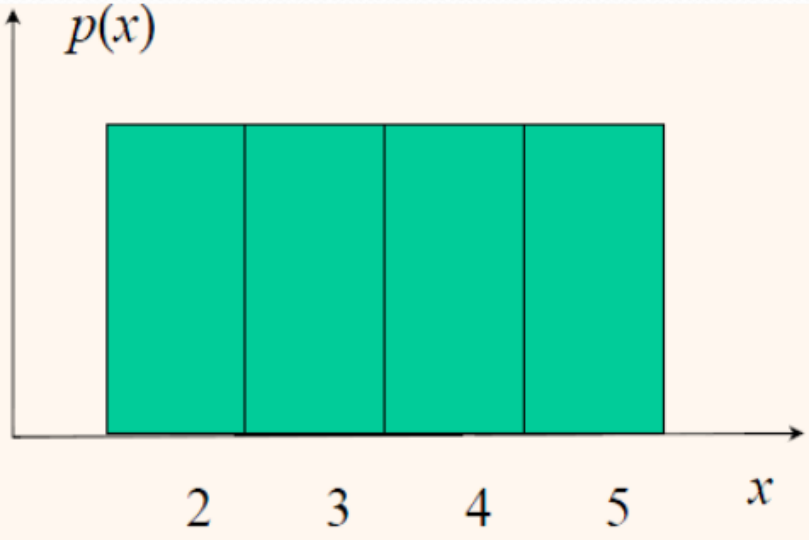

- Parâmetros:

$$\mu = \frac{1}{N}\sum_{i=1}^{N} x_i = \frac{1}{4}(2+3+4+5) = 3{,}5$$

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i-\mu)^2 = \frac{1}{4}\left[(2-3{,}5)^2+(3-3{,}5)^2+(4-3{,}5)^2+(5-3{,}5)^2\right] = 1{,}25$$

DISTRIBUIÇÃO AMOSTRAL DA MÉDIA

Exemplo 1:

- Amostragem aleatória simples de tamanho n = 2.
  - Construção da distribuição amostral da média:

Amostras possíveis	$\overline{X}$	Probabilidade
(2, 2)	2,0	$1/16$
(2, 3), (3, 2)	2,5	$2/16$
(2, 4), (3, 3), (4, 2)	3,0	$3/16$
(2, 5), (3, 4), (4, 3), (5, 2)	3,5	$4/16$
(3, 5), (4, 4), (5, 3)	4,0	$3/16$
(4, 5), (5, 4)	4,5	$2/16$
(5, 5)	5,0	$1/16$

Exemplo 1:

Média e variância da média amostral

$$E(\overline{X}) = 2\left(\frac{1}{16}\right) + 2{,}5\left(\frac{2}{16}\right) + 3\left(\frac{3}{16}\right) + 3{,}5\left(\frac{4}{16}\right) + 4\left(\frac{3}{16}\right) + 4{,}5\left(\frac{2}{16}\right) + 5\left(\frac{1}{16}\right) = 3{,}5$$

$$V(\overline{X}) = (2-3{,}5)^2\,\frac{1}{16} + (2{,}5-3{,}5)^2\,\frac{2}{16} + \ldots + (5-3{,}5)^2\,\frac{1}{16} = 0{,}625$$

DISTRIBUIÇÃO AMOSTRAL DA MÉDIA

Exemplo 1:

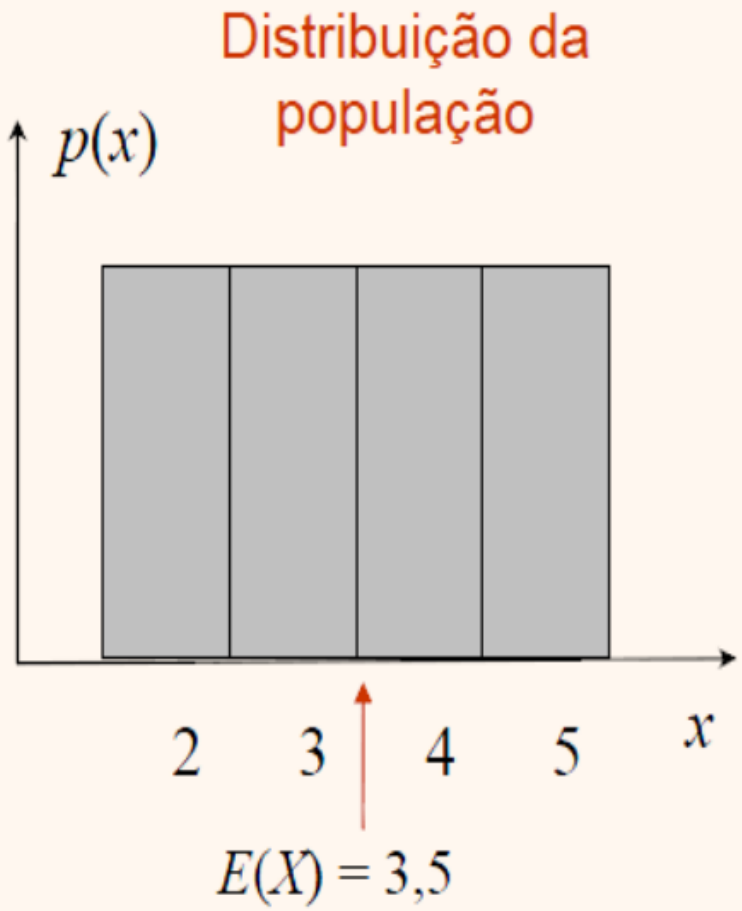

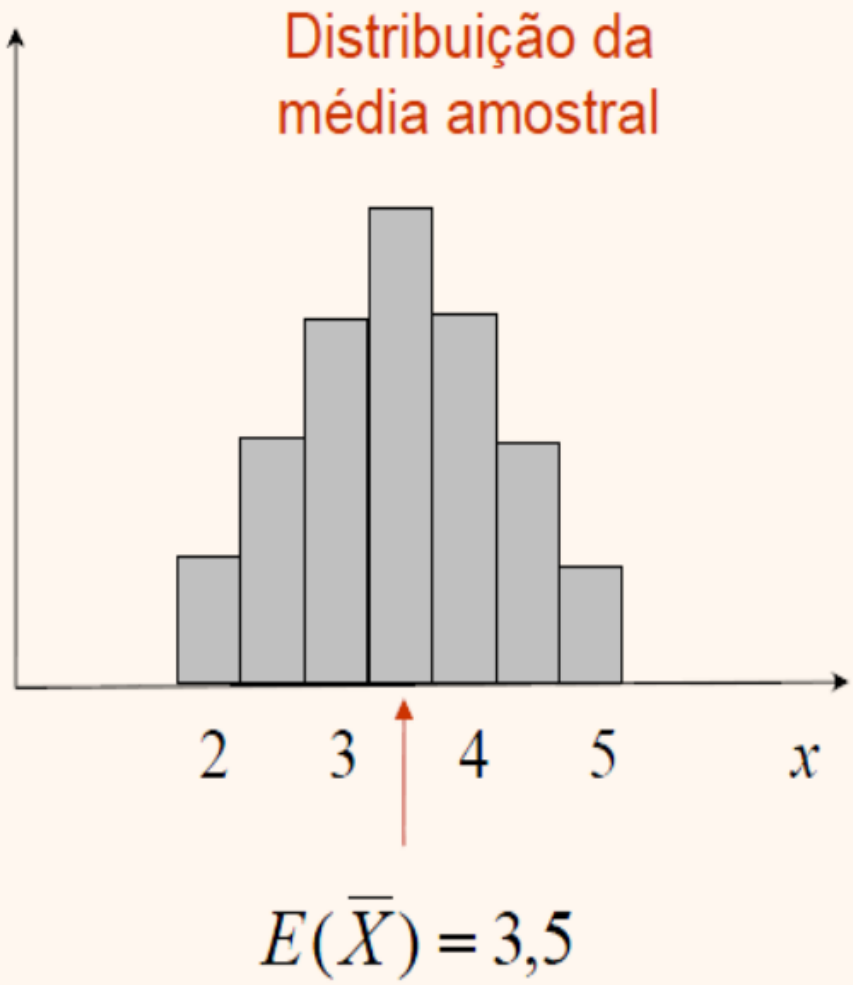

Distribuição Amostral de $\bar{X}$ quando a população é normal

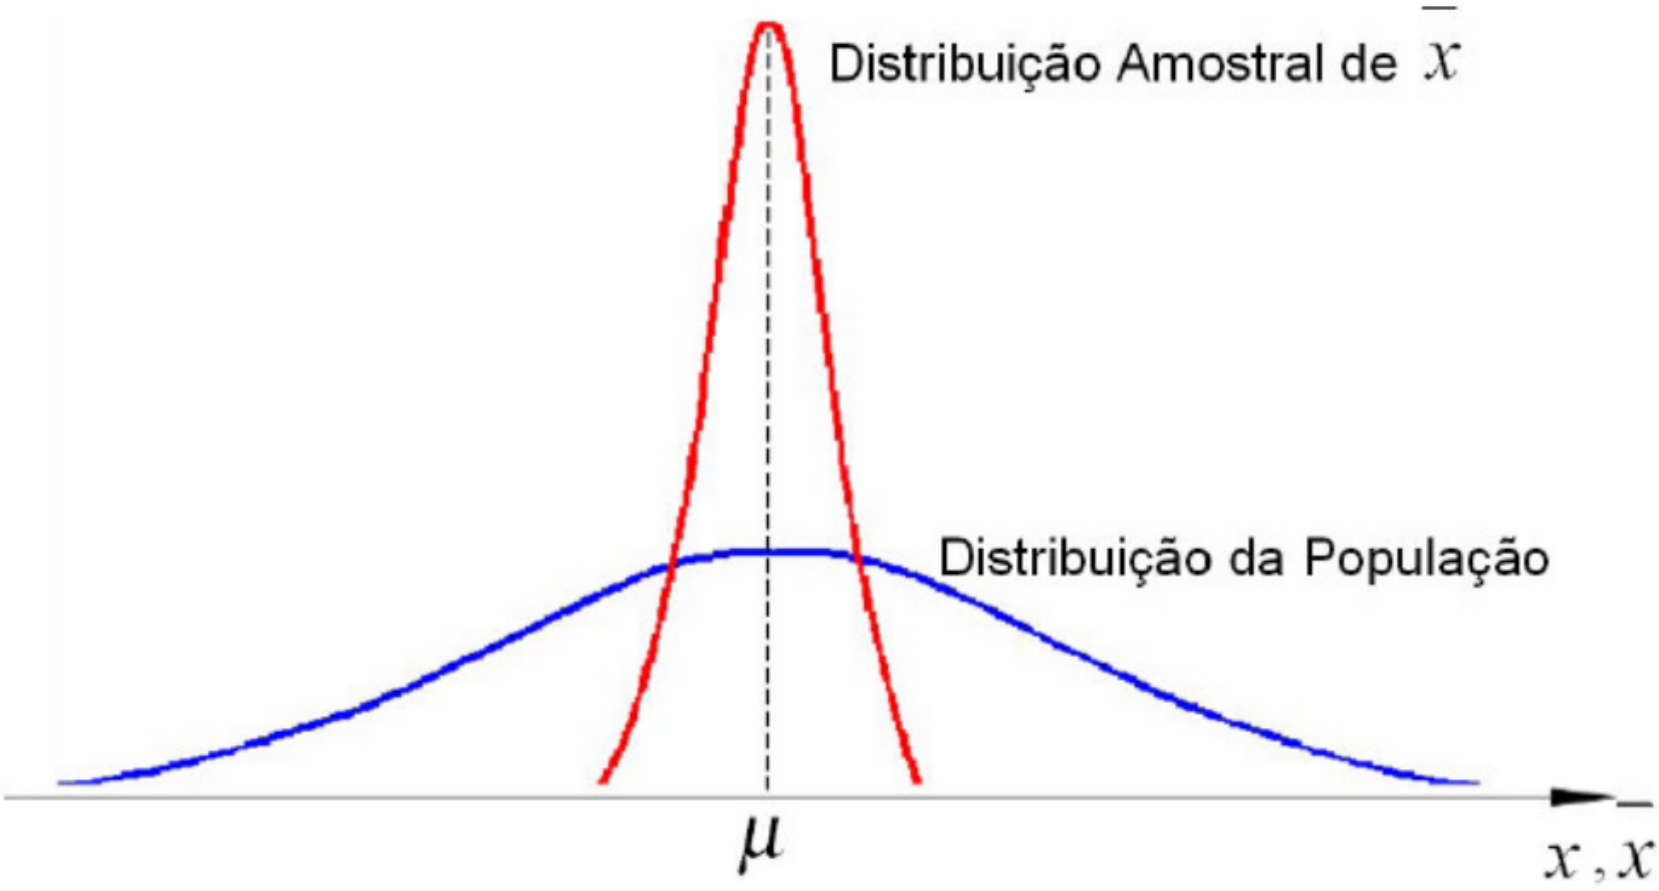

Distribuição Amostral de $\bar{X}$ quando a população não é normal e a amostra é suficientemente grande

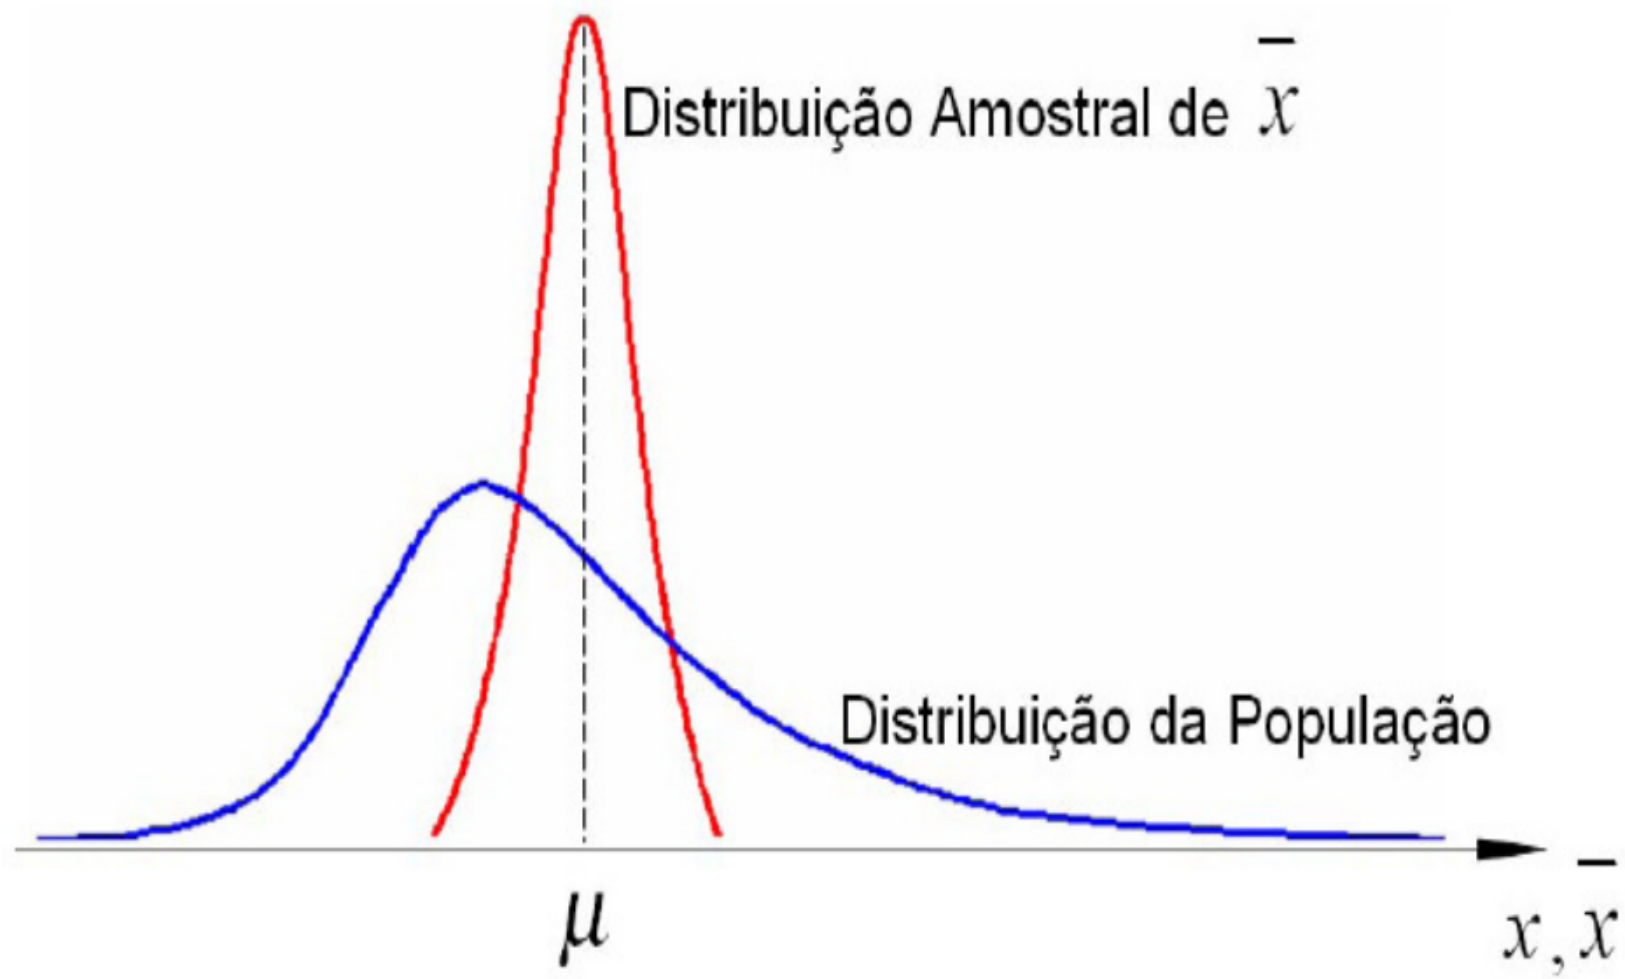

Por que aparece a Normal? (Explicação intuitiva)

Quando combinamos muitas observações, um padrão começa a surgir.

Na prática estatística:

- Cada observação individual tem sua própria variabilidade
- Diferenças individuais se compensam
- O resultado médio tende a se estabilizar

"O acaso individual vira regularidade coletiva."

Mensagem central

Não é o dado individual que vira Normal

É a **média de muitos dados** que se aproxima da Normal.

Essa é a essência do **Teorema Central do Limite**.

Teorema Central do Limite no dia a dia

Pense em medir algo repetidamente:

- Os valores individuais podem variar bastante
- As médias de grupos diferentes variam *menos*
- Essas médias tendem a formar uma **curva simétrica** (forma de sino)

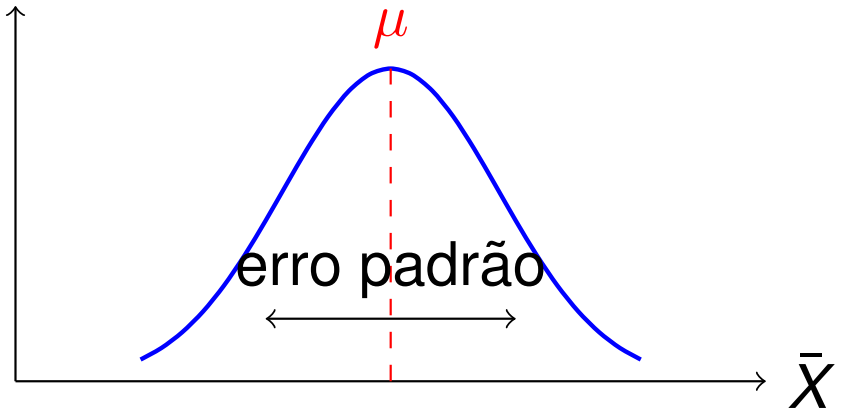

- Quanto **maior** o n, **mais concentrada** a distribuição
- Quanto **maior** o n, **mais próxima** da Normal

Distribuição Amostral da Média (σ Conhecido)

Se a população tem média μ e desvio padrão σ, então:

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma}{\sqrt{n}}\right) \tag{1}$$

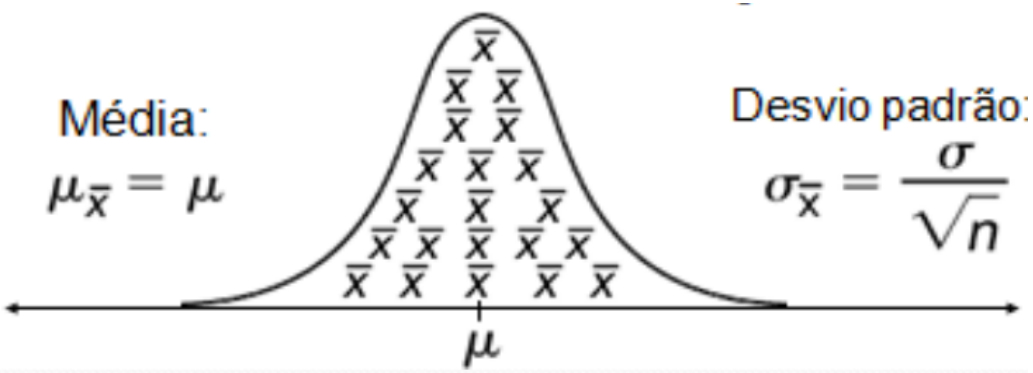

Teorema Central do Limite (TCL)

Para amostras grandes ($n \geq 30$), $\bar{X}$ será aproximadamente normal, mesmo que a população não seja normal.

Distribuição Amostral da Média (σ Desconhecido)

Se σ é desconhecido, usamos o estimador s:

$$\bar{X} \sim t_{n-1}\left(\mu, \frac{s}{\sqrt{n}}\right) \tag{2}$$

Distribuição t de Student

Quando n é pequeno, a distribuição t tem caudas mais largas que a normal, refletindo maior incerteza.

Distribuição Amostral da Proporção

Se a população tem proporção p, a distribuição amostral de $\hat{p}$ é:

$$\hat{p} \sim \mathcal{N}\left(p, \sqrt{\frac{p(1-p)}{n}}\right) \tag{3}$$

Condições de Normalidade

A aproximação normal é válida se $np \geq 5$ e $n(1-p) \geq 5$.

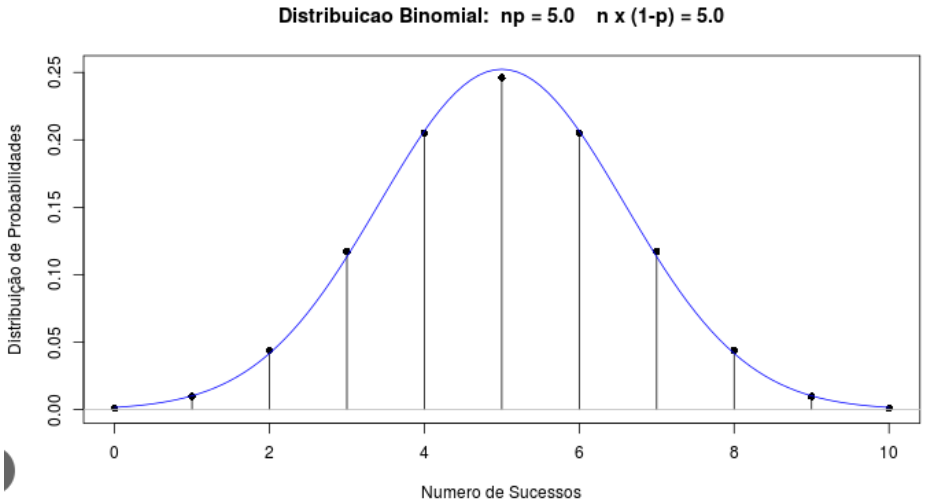

Quando a aproximação Normal é adequada?

Para a média amostral $\bar{X}$:

$$n \geq 30$$

- Condição prática, não teórica
- Funciona bem mesmo que a população original **não** seja Normal
- Se a população já é Normal, vale para **qualquer** n

Para a proporção amostral $\hat{p}$:

$$np \geq 5 \quad \text{e} \quad n(1-p) \geq 5$$

Garantem que há observações suficientes nas duas categorias.

Sempre padronize antes de calcular probabilidades

A padronização permite trabalhar em uma escala comum:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

O que o Z indica:

- Quantos erros padrão um valor está acima ou abaixo do esperado
- Quão comum ou incomum é uma estimativa observada

Só após padronizar podemos usar a Normal para calcular probabilidades.

Probabilidades com a Normal: o que queremos calcular

Após obter o valor de Z, os cálculos mais comuns são:

$P(Z < z) = P(Z \leq z)$

Probabilidade de observar valores menores que z

$P(Z > z) = P(Z \geq z)$

Probabilidade de observar valores maiores que z

$P(a < Z < b) = P(a \leq Z \leq b)$

Probabilidade de observar valores entre a e b

Usando o R para a Normal padrão

Função principal:

`pnorm(z)`

- `pnorm(z)` calcula $P(Z < z)$
- A Normal padrão tem média 0 e desvio padrão 1
- Para $P(Z > z)$, use `1 - pnorm(z)`
- Para $P(a < Z < b)$, use `pnorm(b) - pnorm(a)`

Exemplos

`pnorm(1.5)` $\approx 0,933$

`1 - pnorm(1.5)` $\approx 0,067$

`pnorm(1.5) - pnorm(-1.5)` $\approx 0,866$

Exemplo 2 - Onde tende a ficar a média amostral?

Enunciado:

Estudos anteriores indicam que o tempo de resposta de um servidor tem:

- Média populacional $\mu = 5$ ms
- Desvio padrão populacional $\sigma = 2$ ms

Uma **amostra com** $n = 36$ **requisições** é analisada.

A condição $n \geq 30$ está satisfeita.

Pergunta

Qual é a probabilidade de a média amostral do tempo de resposta ficar **entre 4.5 e 5.5 ms**?

Essa pergunta avalia se uma média nesse intervalo é *esperada* ou *incomum*.

Exemplo 2 - Resolução passo a passo

Passo 1: Erro padrão da média

$$EP = \frac{\sigma}{\sqrt{n}} = \frac{2}{\sqrt{36}} = \frac{2}{6} = 0,333$$

Passo 2: Padronização dos limites

$$Z_1 = \frac{4,5 - 5}{0,333} \approx -1,50 \qquad Z_2 = \frac{5,5 - 5}{0,333} \approx 1,50$$

Passo 3: Cálculo da probabilidade

$$P(4,5 \leq \bar{X} \leq 5,5) = P(-1,50 \leq Z \leq 1,50)$$

`pnorm(1.5) - pnorm(-1.5)` $\approx 0,866$

Interpretação

A probabilidade é de aproximadamente 86,6%.
Valores entre 4,5 e 5,5 ms são **esperados** e comuns.

Exercício 1 - Média Amostral (Salário de Recém-Formados)

O salário anual de recém-formados em Estatística tem distribuição com:

- Média populacional $\mu =$ R$ 60.000
- Desvio padrão populacional $\sigma =$ R$ 10.000

Um professor coleta uma **amostra aleatória com** $n = 40$ **recém-formados**.

Pergunta

Qual é a probabilidade de que o salário médio nessa amostra seja **inferior a R$ 55.000**?

Exercício 1 - Média Amostral (Salário de Recém-Formados)

Exercício 1 - Média Amostral (Salário de Recém-Formados)

Vamos entender Melhor - Distibuição Amostral!

Um estatístico é escolhido ao acaso nessa amostra. Qual é a probabilidade dele ter um salário anual **inferior a R$ 55.000**?

Que conclusões você pode tirar?

Exercício 1 - Média Amostral (Salário de Recém-Formados)

E se o Desvio Padrão Populacional é desconhecido?

Considere que não sabemos nenhuma informação sobre a dispersão da população e calculamos o desvio padrão da amostra - $s = 10.000$.

Que distribuição seria indicado usarmos?

Exercício 1 - Comparação: Normal vs t-Student

Cenário: σ desconhecido, usando $s = 10.000$ com $n = 40$

Distribuição Normal

$$Z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}}$$

$$z = \frac{55.000 - 60.000}{10.000/\sqrt{40}} \approx -3,16$$

$$P(Z < -3,16) \approx \mathbf{0,0008}$$

Distribuição t-Student (gl = 39)

$$t = \frac{\bar{x} - \mu}{s/\sqrt{n}}$$

$$t = \frac{55.000 - 60.000}{10.000/\sqrt{40}} \approx -3,16$$

$$P(T_{39} < -3,16) \approx \mathbf{0,00079}$$

Conclusão

Com $n = 40 > 30$, as probabilidades são **praticamente idênticas**!

Normal: $0,0008$ t-Student: $0,00079$

Por isso, para $n \geq 30$, a aproximação normal é perfeitamente adequada mesmo com σ desconhecido.

Exemplo 3 - Variação da proporção amostral

Enunciado:

Em uma fábrica de componentes eletrônicos sabe que:

- A proporção de itens defeituosos é $p = 0,10$ (10%)

Um estatístico coleta uma **amostra com** $n = 200$ **itens**.

Verificação das condições:

$np = 200 \cdot 0,10 = 20 \geq 5 \qquad n(1-p) = 200 \cdot 0,90 = 180 \geq 5$

A aproximação Normal é adequada!

Pergunta

Qual a probabilidade de a proporção amostral de defeituosos ficar **entre 0,07 e 0,13** (7% a 13%)?

Exemplo 3 - Resolução passo a passo

Passo 1: Erro padrão da proporção

$$EP = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0,10 \cdot 0,90}{200}} = \sqrt{0,00045} \approx 0,0212$$

Passo 2: Padronização dos limites

$$Z_1 = \frac{0,07 - 0,10}{0,0212} \approx -1,42 \qquad Z_2 = \frac{0,13 - 0,10}{0,0212} \approx 1,42$$

Passo 3: Cálculo da probabilidade

$$P(0,07 \leq \hat{p} \leq 0,13) = P(-1,42 \leq Z \leq 1,42)$$

```
pnorm(1.42) - pnorm(-1.42)
```
$\approx 0,844$

Interpretação

A probabilidade é de aproximadamente 84,4%.
Proporções entre 7% e 13% são **comuns** para $n = 200$.

Exercício 2 - Proporção Amostral (Intenção de Votos)

Em uma cidade, sabe-se que a proporção de eleitores favoráveis a uma certa política pública é $p = 0,55$ (55%).

Um instituto de pesquisa entrevista uma **amostra com** $n = 500$ **eleitores**.

Pergunta

Qual a probabilidade de que a proporção amostral de favoráveis na pesquisa seja **superior a 58%**?

Exercício 2 - Proporção Amostral (Intenção de Votos)

O papel do tamanho amostral

n maior $\Rightarrow$ estimativas mais precisas

Erro padrão:

- $EP = \dfrac{\sigma}{\sqrt{n}}$
- Dobre n, EP reduz $\sqrt{2} \approx 1,41$ vezes
- Quadruplique n, EP **cai pela metade**

Consequências:

- Estimativas **mais concentradas**
- **Menor variação** entre amostras
- Maior **confiabilidade**

Leitura prática

Estudos pequenos: variam muito, mesmo com coleta correta.
Estudos grandes: resultados mais estáveis e reproduzíveis.

Exercício 3 - Consumo de Combustível

Um modelo popular de carro tem um consumo de combustível na estrada com Média populacional $\mu = 12,5$ km/l e Desvio padrão populacional $\sigma = 1,2$ km/l

Uma revista especializada testa uma **amostra com** $n = 35$ **carros** deste modelo.

Pergunta

Qual é a probabilidade de que a média amostral do consumo seja **inferior a 12 km/l**?

Exercício 4 - Controle de Qualidade

Um processo produtivo de lâmpadas opera com uma proporção de defeituosos de $p = 0,03$ (3%).

O controle de qualidade inspeciona uma **amostra com** $n = 300$ **lâmpadas**.

Pergunta

Qual a probabilidade de que a proporção amostral de lâmpadas defeituosas
seja **inferior a 1,5%**?