Pesquisa Aplicada à Estatística

Aula 3.1 Usando o R: Distribuições Binomial e Normal

Distribuição Binomial - Receita no R

Objetivo

Utilizar o **R como calculadora** para obter probabilidades e medidas resumo.

Passo 1 - Parâmetros

```
n <- número_de_tentativas
p <- probabilidade_de_sucess
```

Passo 2 - Probabilidades

- Exatamente *x* sucessos:

```
dbinom(x, size = n,
prob = p)
```

Passo 2 - Probabilidades

- No máximo *x* sucessos:

```
pbinom(x, size = n,
prob = p)
```

Passo 3 - Medidas

- Média:

```
n * p
```

- Desvio padrão:

```
sqrt(n * p * (1 - p))
```

Exemplo 1

Situação-problema

Em uma campanha de marketing digital, sabe-se que a probabilidade de um visitante realizar uma **compra** após acessar um site é de $p = 0{,}2$. Suponha que $n = 5$ visitantes sejam observados de forma independente. Seja X o número de visitantes que realizam a compra.

Questões

- Calcule a probabilidade de exatamente 2 visitantes realizarem a compra.
- Calcule a probabilidade de, no máximo, 2 visitantes realizarem a compra.
- Determine a média e a variância de X.

Modelo probabilístico:

$$X \sim \text{Binomial}(n = 5,\ p = 0{,}2)$$

Exemplo 1 - Calculando quantidades de interesse

1) Probabilidade de exatamente 2 compras

$$P(X=2) = \binom{5}{2}(0{,}2)^2(0{,}8)^3$$

$$\binom{5}{2} = \frac{5!}{2!\,3!} = \frac{5\cdot 4}{2\cdot 1} = 10$$

$$P(X=2) = 10\cdot 0{,}04\cdot 0{,}512 = 0{,}2048$$

2) Probabilidade de no máximo 2 compras

$$P(X\leq 2) = P(0)+P(1)+P(2)$$

$$= 0{,}32768 + 0{,}4096 + 0{,}2048$$

$$= 0{,}94208$$

3) Média

$$E[X] = n\cdot p = 5\cdot 0{,}2 = 1$$

4) Desvio Padrão

$$\mathrm{DP}(X) = \sqrt{n\cdot p\cdot(1-p)}$$

$$= \sqrt{5\cdot 0{,}2\cdot 0{,}8} = 0{,}89$$

Interpretação

Em média, espera-se **1 compra** a cada 5 visitantes observados. O desvio padrão, 1 compra, é alto, mostrando uma grande dispersão..

Exemplo 1 - Resolução usando o R

Modelo

- $n = 5$ visitantes
- $p = 0{,}2$ (realizar compra)
- X: número de visitantes que compram

1) Probabilidade de exatamente 2 compras

```
dbinom(2, size = 5,
prob = 0.2)
```

$P(X = 2) = 0{,}2048$

2) Probabilidade de no máximo 2 compras

```
pbinom(2, size = 5,
prob = 0.2)
```

$P(X \leq 2) = 0{,}94208$

3) Média

```
n <- 5
p <- 0.2
n * p
```

$E[X] = 1$

4) Desvio padrão

```
sqrt(n * p * (1 - p))
```

$DP(X) \approx 0{,}89$

Interpretação Espera-se, em média, que **1 visitante realize a compra** a cada 5 acessos observados, com uma variação típica de aproximadamente **1 visitante** para mais ou para menos.

Exemplo 2: Doença Cardiovascular - Resolução com R

Problema de Saúde Pública

Estudo com 10 homens $>$ 60 anos, sedentários e fumantes.
Probabilidade de desenvolver DCV nos próximos 8 anos: $p = 0.40$ (40%)

1. No R

Parâmetros da binomial:
Variável: $X \sim \text{Binomial}(n = 10, p = 0.4)$
X = número de casos de DCV

2. Nenhum caso de DCV

```
dbinom(0, size = 10,
 prob = 0.4)
```

$P(X = 0) = 0.0060 \quad (0.60\%)$
Interpretação: Muito baixa probabilidade (0.6%)

3. Média e Desvio Padrão

```
media <- n * p
DP <- sqrt(n * p * (1-p))
```

Média: 4 e DP: 1.549

4. Pelo menos 3 casos DCV

```
1 - pbinom(2, n, p)
```

$P(X \geq 3) = 1 - P(X \leq 2) = 0.8328$
Interpretação: 83.28% de chance de $>$ 3 casos

Exemplo 2 - Resolução com R

Enunciado do Problema

Estudo com 10 homens $>$ 60 anos, sedentários e fumantes. A probabilidade de desenvolver doença cardiovascular (DCV) nos próximos 8 anos é 40% ($p = 0.4$). Seja X o número de indivíduos que desenvolvem DCV ($X \sim \text{Binomial}(n = 10, p = 0.4)$).

Código R

```
# CONFIGURAÇÃO DO PROBLEMA
n <- 10          # número de indivíduos
p <- 0.4         # probabilidade de DCV

# 1. PROBABILIDADE DE NENHUM CASO
P_nenhum <- dbinom(0, size = n,
prob = p)

# 2. PROBABILIDADE DE $?3$ CASOS
P_pelo_menos_3 <- 1 - pbinom(2,
size = n,
prob = p)

 # 3. MÉDIA (VALOR ESPERADO)
media <- n * p

# 4. DESVIO PADRÃO
dp <- sqrt(n * p * (1 - p))
```

Doença Cardiovascular - Resolução com R

Respostas

1. $P(X = 0) = 0.0060 \quad (0.60\%)$
2. $P(X \geq 3) = 0.8328 \quad (83.28\%)$
3. $E(X) = 4$ casos
4. $DP(X) = 1.549$ casos

Interpretação para Gestão

- É **muito improvável** (0.6%) que nenhum desenvolva DCV
- É **muito provável** (83.3%) que pelo menos 3 desenvolvam DCV
- Espera-se **4 casos em média** ± 1.5 casos
- Resultado justifica **intervenções preventivas** para redução de riscos.

Exercício 1: Detecção automática de fraudes

Um sistema automático de detecção de fraudes utilizado por uma empresa de meios de pagamento identifica corretamente uma transação fraudulenta com probabilidade de 90%. Em um conjunto de $n = 8$ transações que **de fato são fraudes**, defina X como o número de transações que o sistema classificará como **fraude**.

$$X \sim \text{Binomial}(n = 8,\ p = 0{,}9)$$

Calcule:

1. Qual a probabilidade de que **todas as transações sejam corretamente identificadas como fraude**?
2. Qual a probabilidade de que **pelo menos 6 transações** sejam corretamente identificadas como fraude?
3. Em média, **quantas transações** desse conjunto devem ser corretamente identificadas como fraude?

Execício 2: Administração correta de medicação

O estatístico do HNSN foi chamado para avaliar os riscos erros na administração de determinado medicamento. Em uma ala pediátrica, cada enfermeiro(a) possui 95% de probabilidade de administrar corretamente um medicamento em um turno. Considere $n = 10$ administrações realizadas por um mesmo profissional. Seja X o número de administrações corretas.

$$X \sim \text{Binomial}(n = 10,\ p = 0{,}95)$$

Calcule:

1. Qual a probabilidade de que **todas as administrações sejam corretas** nesse turno?
2. Qual a probabilidade de que **o profissional cometa pelo menos 2 erros** nesse turno?
3. Em média, **quantas administrações corretas** se espera nesse plantão?
4. O que o estatístico pode concluir?

Distribuição Normal - Receita no R

Objetivo

Utilizar o **R como calculadora** para distribuição normal.

Passo 1 - Parâmetros

```
mu <- media
sigma <- desvio_padrao
```

Passo 2 - Probabilidades

- $P(X < x)$:

```
pnorm(x, mean = mu,
sd = sigma)
```

Passo 2 - Probabilidades

- $P(X > x)$:

```
1 - pnorm(x, mean = mu,
sd = sigma)
```

- $P(a < X < b)$:

```
pnorm(b, mu, sigma) -
pnorm(a, mu, sigma)
```

Passo 3 - Valores Críticos

- Percentil p:

```
qnorm(p, mean = mu,
sd = sigma)
```

Exemplo 3

Situação-problema

Em um centro de logística, estudos indicam que o tempo de processamento de um pedido (desde a separação até a liberação para envio) segue distribuição normal, com média $\mu = 7$ horas e desvio padrão $\sigma = 2$ horas. Seja X o tempo de processamento de um pedido.

Questões

- Calcule a probabilidade de um pedido ser processado em menos de 5 horas.
- Calcule a probabilidade de um pedido demorar mais de 10 horas para ser processado.
- Determine o tempo que separa os 25% dos pedidos com menor tempo de processamento (1º quartil).

Modelo probabilístico:

$$X \sim N(\mu = 7,\ \sigma = 2)$$

Exemplo 3 - Resolução usando o R

Modelo

- $\mu = 7$ horas
- $\sigma = 2$ horas
- $X \sim N(7, 2^2)$

1) Probabilidade de processamento < 5 horas

```
pnorm(5, mean = 7,
sd = 2)
```

$P(X < 5) = 0.1587$

2) Probabilidade de processamento > 10 horas

```
1 - pnorm(10, mean = 7,
sd = 2)
```

$P(X > 10) = 0.0668$

3) 1º quartil (25% mais rápidos)

```
qnorm(0.25, mean = 7,
sd = 2)
```

$Q_1 = 5.65$ horas

4) Intervalo 95% central

```
qnorm(0.025, 7, 2)   # 2.5%
qnorm(0.975, 7, 2)   # 97.5%
```

$[3.08, 10.92]$ horas

Interpretação

- 15.9% dos pedidos são processados em menos de 5 horas
- 6.7% dos pedidos demoram mais de 10 horas
- 95% dos pedidos são processados entre aproximadamente 3 e 11 horas

Exemplo 4: Glicemia Gestacional

Problema de Saúde Pública

Glicemia de jejum em gestantes do 3º trimestre na Paraíba: $\mu = 85$ mg/dL, $\sigma = 10$ mg/dL. $X \sim N(85, 10^2)$ onde X = glicemia de jejum

1. No R

Parâmetros da normal:

```
mu <- 85
sigma <- 10
```

2. Hiperglicemia (> 100 mg/dL)

```
1 - pnorm(100, mu, sigma)
```

$P(X > 100) = 0.0668 \quad (6.68\%)$

Interpretação: 6.7% risco de hiperglicemia

3. Hipoglicemia (< 70 mg/dL)

```
pnorm(70, mean = mu,
sd = sigma)
```

Resultado:
$P(X < 70) = 0.0668 \quad (6.68\%)$

Interpretação: 6.7% risco de hipoglicemia

Exemplo 4: Glicemia Gestacional

4. Percentis importantes

P5 (baixo):

```
qnorm(0.05, mu, sigma)
# 68.6 mg/dL
```

P95 (alto):

```
qnorm(0.95, mu, sigma)
# 101.4 mg/dL
```

Aplicação na Gestão

- **6.7% hipoglicemia:** Necessidade de monitoramento
- **6.7% hiperglicemia:** Risco de diabetes gestacional
- **P5-P95:** Faixa de referência para população
- **Útil para:** Protocolos de rastreamento

Exemplo 4 - Resolução com R

Enunciado do Problema

Glicemia de jejum em gestantes do 3º trimestre: $\mu = 85$ mg/dL, $\sigma = 10$ mg/dL.
$X \sim N(85, 10^2)$ onde X = glicemia de jejum

Código Completo em R

```
# CONFIGURAÇÃO DO PROBLEMA
mu <- 85          # média glicemia
sigma <- 10       # desvio padrão

# 1. HIPOGLICEMIA (<70 mg/dL)
P_hipo <- pnorm(70, mean = mu, sd = sigma)

# 2. HIPERGLICEMIA (>100 mg/dL)
P_hiper <- 1 - pnorm(100, mean = mu, sd = sigma)

# 3. FAIXA NORMAL (80-90 mg/dL)
P_normal <- pnorm(90, mu, sigma) - pnorm(80, mu, sigma)

# 4. PERCENTIL 95% (P95)
P95 <- qnorm(0.95, mean = mu, sd = sigma)

# 5. PERCENTIL 5% (P5)
P5 <- qnorm(0.05, mean = mu, sd = sigma)
```

Glicemia Gestacional - Respostas e Interpretação

Respostas

1. $P(X < 70) = 0.0668$ (6.68% risco hipoglicemia)
2. $P(X > 100) = 0.0668$ (6.68% risco hiperglicemia)
3. $P(80 < X < 90) = 0.3829$ (38.29% na faixa central)
4. $P_{95} = 101.4$ mg/dL (95% abaixo deste valor)
5. $P_5 = 68.6$ mg/dL (5% abaixo deste valor)

Interpretação para Gestão

- **13.4% das gestantes** têm glicemia fora da faixa ideal (6.7% baixa + 6.7% alta)
- **Faixa de referência (P5-P95):** 68.6 a 101.4 mg/dL
- **Valores clínicos importantes:**
  - $<$ 70 mg/dL: Avaliar para hipoglicemia
  - $>$ 100 mg/dL: Rastrear diabetes gestacional
- **Aplicação:** Definição de pontos de corte em protocolos de pré-natal
- **Planejamento:** Estimar demanda por testes de tolerância à glicose

Conclusão: A distribuição normal permite estimar prevalências e definir valores de referência para ações em saúde pública.

Exercício 3: Desempenho em uma prova padronizada

Em uma prova padronizada aplicada a candidatos de um concurso público, a pontuação final segue aproximadamente uma distribuição normal, com média $\mu = 140$ pontos e desvio padrão $\sigma = 20$ pontos. Defina X como a pontuação de um candidato.

$$X \sim N(\mu = 140, \sigma = 20)$$

Calcule:

1. Qual a probabilidade de um candidato obter pontuação **superior a 160 pontos**?
2. Qual a probabilidade de a pontuação estar **entre 120 e 150 pontos**?
3. Qual o valor da pontuação que separa os **10% com maiores notas** (P90)?
4. Em um grupo de 100 candidatos, **quantos esperamos** com pontuação acima de 180 pontos?

Exercício 4: Tempo de Espera em UPA

O tempo de espera para atendimento médico em UPA segue distribuição normal com média $\mu = 90$ minutos e desvio padrão $\sigma = 30$ minutos. Seja X o tempo de espera em minutos.

$$X \sim N(\mu = 90, \sigma = 30)$$

Calcule:

1. Qual a probabilidade de um paciente esperar **mais de 2 horas** (120 minutos)?
2. Qual a probabilidade de espera ser **inferior a 1 hora** (60 minutos)?
3. Qual o tempo máximo que **75% dos pacientes** esperam (percentil 75)?
4. Se a UPA atende 200 pacientes/dia, **quantos esperam mais de 3 horas** (180 minutos)?