Pesquisa Aplicada à Estatística

Alguns Testes de Hipóteses Especiais

Departamento de ESTATÍSTICA

Testes de Normalidade: Por que isso importa?

A Escolha do Teste Certo Depende Disso

- **Dados Normais:** Podemos usar testes **paramétricos**
- ✓ Mais poder estatístico (maior chance de detectar um efeito real)
- **Dados Não-Normais:** Precisamos usar testes **não-paramétricos**
- ✓ Não exigem distribuição específica (são de distribuição livre)

Exemplos Práticos em Diferentes Áreas

- Diâmetro de peças (controle de qualidade, normal) $\rightarrow$ **Teste T ou Z**
- Renda domiciliar (assimétrica) $\rightarrow$ **Teste não-paramétrico**

Traduzindo a Hipótese Nula

H_0: "Os dados seguem uma distribuição normal"

$\downarrow$

"Posso usar o teste paramétrico com segurança."

Testes de Normalidade vs. Testes Não-Paramétricos

Conceitos Fundamentais

Testes não-paramétricos = "Não assumem normalidade"

Testes de normalidade = "Testam a normalidade"

A Diferença Está no Papel

Testes de normalidade = DIAGNÓSTICO

(você usa ANTES)

Testes não-paramétricos = ALTERNATIVA

(você usa QUANDO o diagnóstico indica problemas)

Analogia

Teste de normalidade:	Verificação da estrada (checa as condições)
Testes paramétricos:	Carro de Fórmula 1 (só funciona em pistas perfeitas)
Testes não-paramétricos:	Jeep 4x4 (funciona em qualquer terreno)

Antes do Teste: Análise Visual!

Histograma + Curva Normal

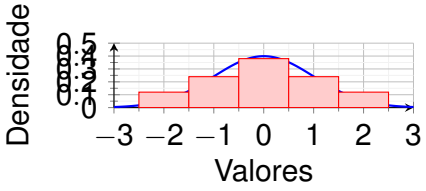

Provavelmente Normal

(Forma de sino, simétrico)

Q-Q Plot (Gráfico de Quantis)

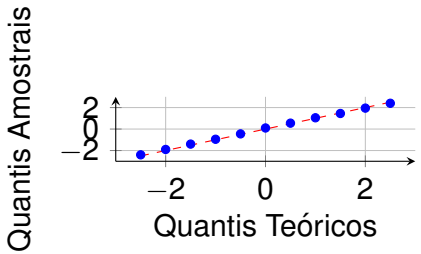

Provavelmente Normal

(Pontos próximos à linha reta)

Não Normal (Assimétrico)

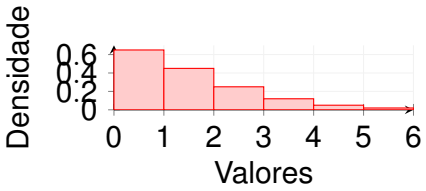

Não Normal (QQ-Plot)

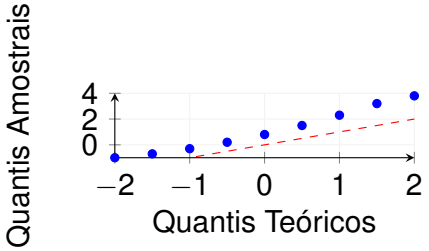

Regra de Ouro

A inspeção visual é tão importante quanto o teste de hipótese. Avaliar os dois é o mais indicado.

Os Testes Formais: Qual Escolher?

Teste	Recomendação e Características
Shapiro-Wilk	O mais recomendado para a maioria das situações. **Alta potência**, especialmente para amostras pequenas ($n < 50$). É o padrão no R.
Kolmogorov-Smirnov (Lilliefors)	O teste de Kolmogorov-Smirnov tradicional é mais indicado quando você quer comparar com uma distribuição específica (com média e desvio conhecidos). A **correção de Lilliefors** é usada quando estimamos a média e o desvio da amostra. Menos potente que Shapiro-Wilk.
Anderson-Darling	Dá mais peso às **caudas da distribuição**. Muito útil para detectar valores extremos (outliers) que são comuns em dados de áreas como finanças e meteorologia.

Recomendação Prática

1. **Sempre** comece com a análise visual (Histograma/QQ-Plot).
2. Utilize o **teste de Shapiro-Wilk** para confirmar seus achados.

Deixando Claro

1. Esses testes são chamados de **testes de aderência**
2. São testes de hipótese sobre a distribuição dos dados. Eles perguntam: ”Meus dados podem ser modelados por uma distribuição normal?”

Fluxo de Decisão Correta

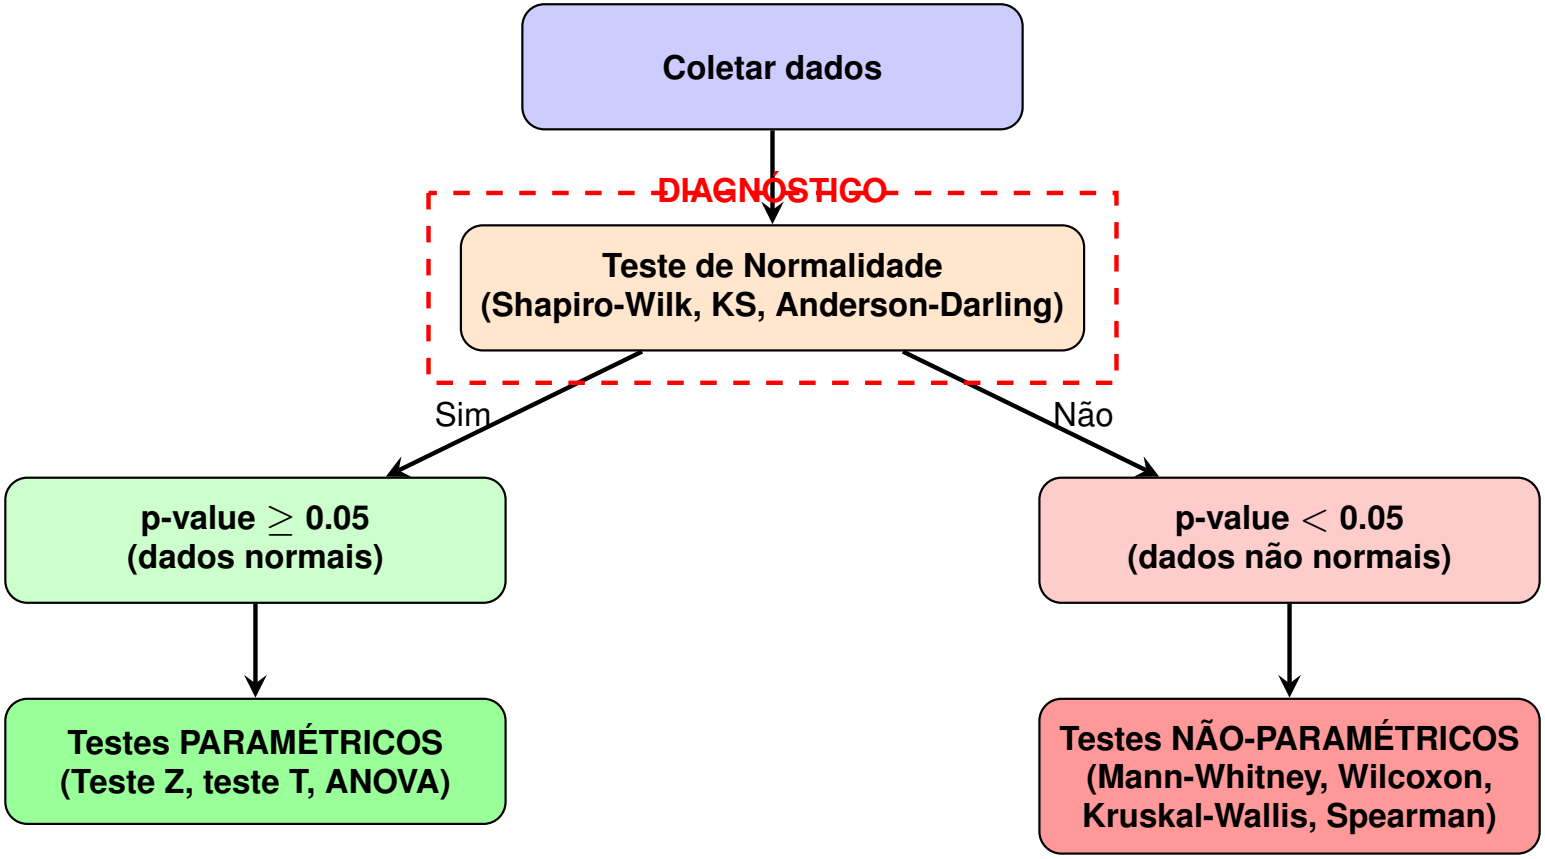

Análise Visual no R: Histograma e Q-Q Plot

Versões com ggplot2 (mais modernas)

```
# Histograma com ggplot2
library(ggplot2)
ggplot(data.frame(dados),
aes(x = dados)) +
geom_histogram(aes(y = ..density..),
bins = 30,
fill = "lightblue",
color = "black") +
stat_function(fun = dnorm,
args = list(mean = mean(dados),
sd = sd(dados)),
color = "red",
size = 1) +
labs(title = "Histograma")
```

```
# Q-Q Plot com ggplot2
library(ggplot2)
ggplot(data.frame(dados),
aes(sample = dados)) +
stat_qq(color = "blue",
size = 2) +
stat_qq_line(color = "red",
size = 1) +
labs(title = "Q-Q Plot",
x = "Quantis Teóricos",
y = "Quantis Amostrais")
```

Interpretação Visual

- **Histograma:** Procurar forma de sino, simetria em torno da média.
- **Q-Q Plot:** Pontos próximos à linha vermelha indicam normalidade. Desvios sistemáticos (curvaturas) indicam assimetria ou caudas pesadas.

Na Prática com R: Teste de Shapiro-Wilk

Comando Básico

```
# shapiro.test(nome_da_sua_variavel)
# Exemplo genérico:
shapiro.test(dados)
```

Hipóteses do Teste

H_0 (Hipótese Nula): Os dados seguem uma distribuição normal.
H_1 (Hipótese Alternativa): Os dados **não** seguem uma distribuição normal.

Como Decidir?

p-value $\geq$ 0.05	**p-value ¡ 0.05**
Não rejeitamos H_0.	**Rejeitamos H_0.**
Sem evidências contra normalidade.	Dados não são normais.
Prática:	**Prática:**
Usar testes paramétricos.	Testes não-paramétricos.

Lembrete

O p-valor é a probabilidade de obter os dados observados (ou algo mais extremo) **se H_0 for verdadeira**. Um p-valor baixo indica que é improvável que os dados venham de uma distribuição normal.

Na Prática com R: Teste de Shapiro-Wilk

Exemplo: Será que os dados de `tempo_entrega` são normais?

```
# Dados: tempo de entrega de um aplicativo (em minutos)
tempo_entrega <- c(28, 30, 32, 35, 29, 31, 45, 33, 28, 30, 65,//
31, 32, 29)

# Realizando o teste de normalidade
shapiro.test(tempo_entrega)

Shapiro-Wilk normality test

data:  tempo_entrega
W = 0.847, p-value = 0.020
```

Interpretação

O p-valor foi $0.02 < 0.05$. Portanto, rejeitamos a hipótese de normalidade. Os dados de `tempo_entrega` **não** são normais. (Possivelmente por causa dos valores 45 e 65, que são outliers).

Exercício 1: Controle de Qualidade na Indústria

Contexto

Uma fábrica de peças automotivas produz pistões para motores. As especificações técnicas exigem que o processo seja estável e que as medidas sigam uma distribuição normal para que os testes de controle estatístico possam ser aplicados.

Dados

```
diametro <- c(50.2, 49.8, 50.1, 50.3, 49.7, 50.0, 50.4, 49.9, 50.2, 50
50.5, 49.6, 50.3, 50.0, 49.8, 50.2, 50.1, 49.9, 50.4, 50.0,
78.3, 49.7, 50.2, 50.1, 50.0)
```

Perguntas

1. Os dados de diâmetro das peças seguem uma distribuição normal?
2. Faça uma análise visual (histograma e Q-Q plot) e depois confirme com o teste de Shapiro-Wilk.
3. Considerando o resultado, quais tipos de testes estatísticos (paramétricos ou não-paramétricos) seriam adequados para analisar essa produção?

Exercício 2: Avaliação de Desempenho Acadêmico

Contexto

Uma professora de Estatística aplicou uma prova final para sua turma. Antes de comparar o desempenho entre os turnos (manhã e noite), ela precisa verificar se as notas seguem uma distribuição normal para decidir entre usar um teste T (paramétrico) ou Mann-Whitney (não-paramétrico).

Dados

```
notas <- c(7.5, 8.0, 6.5, 7.0, 8.5, 6.0, 7.8, 8.2, 6.8, 7.3,
8.1, 6.7, 7.2, 8.3, 6.9, 7.6, 8.4, 6.2, 7.1, 7.9,
7.4, 8.0, 6.6, 7.7, 8.0, 6.3, 7.5, 8.2, 6.8, 7.4)
```

Perguntas

1. As notas dos alunos seguem uma distribuição normal?
2. Construa um histograma com curva normal e um Q-Q plot. O que a análise visual sugere?
3. Aplique o teste de Shapiro-Wilk e interprete o p-valor obtido.
4. Qual seria sua recomendação para a professora: teste paramétrico ou não-paramétrico? Justifique.

Teste Qui-Quadrado: O que é e para que serve?

Definição

O teste qui-quadrado (χ^2) é um teste **não-paramétrico** utilizado para analisar a relação entre **variáveis categóricas** (qualitativas).

Principais Aplicações

- **Teste de Aderência:** Verificar se uma distribuição observada segue uma distribuição teórica esperada.
- **Teste de Independência:** Verificar se duas variáveis categóricas estão associadas.
- **Teste de Homogeneidade:** Comparar distribuições entre diferentes grupos.

Quando Usar?

Quando os dados são **contagens** ou **frequências** em categorias.
Ex: Verificar se o Sexo está associado a Preferência de produto

Teste Qui-Quadrado de Aderência

Objetivo

Verificar se a distribuição observada de uma variável categórica **segue** uma distribuição teórica esperada.

Exemplo Prático

Uma loja espera que suas vendas sejam distribuídas igualmente entre os dias da semana (14,3% por dia). Após coletar dados de uma semana, quer saber se as vendas observadas seguem essa distribuição esperada.

Hipóteses

H_0: As frequências observadas seguem a distribuição esperada

H_1: As frequências observadas NÃO seguem a distribuição esperada

Teste Qui-Quadrado de Independência

Objetivo

Verificar se **duas variáveis categóricas** estão associadas (são dependentes) ou não.

Exemplo Prático

Um pesquisador quer saber se existe relação entre **sexo** (masculino/feminino) e **preferência por um produto** (gosta/não gosta).

Hipóteses

H_0: As variáveis são independentes (não há associação)
H_1: As variáveis são dependentes (há associação)

Importante

Os dados são organizados em uma **tabela de contingência** (cruzamento entre as categorias).

Tabela de Contingência: Organizando os Dados

Estrutura

Os dados são organizados em uma tabela de dupla entrada:

Sexo	**Preferência**		**Total**
	Gosta	**Não Gosta**	
Masculino	30	20	50
Feminino	40	10	50
Total	70	30	100

Interpretação

- **Frequências observadas:** Valores dentro das células (30, 20, 40, 10)
- **Frequências esperadas:** Calculadas supondo H_0 verdadeira (independência)
- Quanto maior a diferença entre observado e esperado, maior a evidência contra H_0

Cálculo das Frequências Esperadas

Fórmula

$$E_{ij} = \frac{(\text{Total da Linha } i) \times (\text{Total da Coluna } j)}{\text{Total Geral}}$$

Exemplo com a tabela anterior

Célula	Cálculo	Esperado
Masculino / Gosta	$(50 \times 70)/100$	35
Masculino / Não Gosta	$(50 \times 30)/100$	15
Feminino / Gosta	$(50 \times 70)/100$	35
Feminino / Não Gosta	$(50 \times 30)/100$	15

Comparação

Observe que os valores observados (30, 20, 40, 10) diferem dos esperados (35, 15, 35, 15). O teste qui-quadrado vai quantificar se essa diferença é estatisticamente significativa.

Estatística do Teste Qui-Quadrado

Fórmula

$$\chi^2 = \sum \frac{(\text{Observado} - \text{Esperado})^2}{\text{Esperado}}$$

Onde o somatório é feito sobre **todas as células** da tabela.

Exemplo de Cálculo

Célula	**Obs**	**Esp**	**Contribuição**
Masc/Gosta	30	35	$(30-35)^2/35 = 0,714$
Masc/Não Gosta	20	15	$(20-15)^2/15 = 1,667$
Fem/Gosta	40	35	$(40-35)^2/35 = 0,714$
Fem/Não Gosta	10	15	$(10-15)^2/15 = 1,667$
Total (χ^2)			**4,762**

Graus de Liberdade e Decisão

Graus de Liberdade (df)

$$df = (\text{número de linhas} - 1) \times (\text{número de colunas} - 1)$$

Para uma tabela 2×2: $df = (2 - 1) \times (2 - 1) = 1$

Decisão

Compara-se o χ^2 calculado com o valor crítico da tabela qui-quadrado:

- Se $\chi^2_{\text{calc}} > \chi^2_{\text{crítico}} \rightarrow$ Rejeita H_0
- Se p-valor $< 0,05 \rightarrow$ Rejeita H_0

Para nosso exemplo

$$\chi^2 = 4,762 \text{ com } df = 1, \text{ p-valor} \approx 0,029$$

p-valor $< 0,05 \rightarrow$ Rejeitamos H_0

Conclusão: Há associação entre sexo e preferência pelo produto.

Comandos no R: Teste Qui-Quadrado

Estrutura Básica

```
# Teste de Independência (com tabela de contingência)
tabela <- table(var1, var2)  # var1 e var2 são fatores
chisq.test(tabela)

# Ou diretamente com os vetores
chisq.test(x = var1, y = var2)
```

Hipóteses do Teste

H_0: As variáveis são independentes (não há associação)
H_1: As variáveis são dependentes (há associação)

Pré-requisitos

- Dados categóricos (transformar com `as.factor()` se necessário)
- Frequências esperadas ≥ 5 em pelo menos 80% das células
- Nenhuma célula com frequência esperada $= 0$

Comandos no R: Como Decidir?

Regra de Decisão

p-value $\geq$ 0.05	**p-value $<$ 0.05**
Não rejeitamos H_0.	**Rejeitamos H_0.**
Não há evidências de associação entre as variáveis.	Há evidências de associação entre as variáveis.
Conclusão: Variáveis independentes.	**Conclusão:** Variáveis dependentes (associadas).

Interpretação do p-valor

O p-valor é a probabilidade de observar os dados (ou algo mais extremo) **se H_0 for verdadeira** (se as variáveis fossem independentes). Um p-valor baixo indica que é improvável que a associação observada seja fruto do acaso.

Exemplo no R: Teste Qui-Quadrado de Independência

Exemplo: Sexo vs. Preferência de Produto

```
# Criando os dados
set.seed(123)
sexo <- factor(rep(c("Masculino", "Feminino"), each = 50))
preferencia <- factor(c(rep("Gosta", 30), rep("Nao Gosta", 20),
rep("Gosta", 40), rep("Nao Gosta", 10)))

# Tabela de contingência
tabela <- table(sexo, preferencia)
print(tabela)

preferencia
sexo        Gosta Nao Gosta
Feminino     40        10
Masculino    30        20

# Teste qui-quadrado
resultado <- chisq.test(tabela)
print(resultado)

Pearson's Chi-squared test with Yates' continuity correction

data:  tabela
X-squared = 4.1667, df = 1, p-value = 0.0412
```

Exemplo no R: Interpretação Detalhada

Resultados

- χ^2 = 4,1667
- df = 1
- p-valor = 0,0412

Interpretação

- p-valor $= 0,0412 < 0,05$
- Rejeitamos H_0
- Conclusão: Há associação estatisticamente significativa entre sexo e preferência pelo produto.

O que significa o p-valor?

Há apenas **4,12%** de chance de observar uma associação como esta (ou mais extrema) **SE** as variáveis fossem independentes na população.

Frequências Esperadas

```
resultado$expected
Gosta Nao Gosta
Fem     35        15
Masc    35        15
```

Exemplo no R: Teste Qui-Quadrado de Aderência

Exemplo: Vendas por dia da semana

```
# Vendas observadas em uma semana (segunda a domingo)
observado <- c(120, 135, 128, 142, 156, 210, 189)

# Probabilidades esperadas (distribuição uniforme = 1/7 cada)
prob_esperada <- rep(1/7, 7)

# Teste qui-quadrado de aderência
chisq.test(observado, p = prob_esperada)

Chi-squared test for given probabilities

data:  observado
X-squared = 37.123, df = 6, p-value = 1.702e-06
```

Interpretação

p-valor $\approx 0,0000017 < 0,05 \rightarrow$ Rejeitamos H_0. As vendas **não** seguem uma distribuição uniforme entre os dias da semana.

Cuidados na Interpretação

Correlação $\neq$ Causalidade

O teste qui-quadrado identifica **associação**, não **causalidade**!

Limitações

- **Tamanho da amostra:** Frequências esperadas muito baixas (< 5) podem invalidar o teste.
- **Solução:** Teste Exato de Fisher (para tabelas 2×2 com amostras pequenas).
- **Não informa a força da associação:** Para isso, use medidas como V de Cramér ou coeficiente de contingência.

Quando usar o Teste Exato de Fisher

```
# Alternativa quando as frequências esperadas são baixas
fisher.test(tabela)
```

Exercício 1: Pesquisa de Satisfação

Contexto

Uma empresa de telefonia quer saber se existe relação entre o **plano contratado** (Básico, Intermediário, Premium) e a **satisfação do cliente** (Satisfeito, Insatisfeito). Foram entrevistados 300 clientes.

Dados

```
# Criar os dados no R
plano <- factor(rep(c("Basico", "Intermediario", "Premium"),
each = 100))
satisfacao <- factor(c(rep("Satisfeito", 60), rep("Insatisfeito", 40),
rep("Satisfeito", 75), rep("Insatisfeito", 25),
rep("Satisfeito", 85), rep("Insatisfeito", 15)))
```

Perguntas

1. Construa a tabela de contingência entre plano e satisfação.
2. Existe associação entre o tipo de plano e a satisfação do cliente? (use $\alpha = 0,05$)
3. Calcule as frequências esperadas. Alguma célula tem valor esperado < 5?
4. Interprete o resultado no contexto do problema.

Exercício 2: Preferência por Produto

Contexto

Um supermercado testou três diferentes embalagens para um mesmo produto e quis verificar se a preferência dos consumidores é influenciada pela embalagem. Os dados coletados mostram a quantidade de pessoas que escolheram cada embalagem.

Dados

```
# Número de pessoas que escolheram cada embalagem
observado <- c(45, 60, 35)

# Embalagens: A, B, C
```

Perguntas

1. Teste a hipótese de que as embalagens são igualmente preferidas (distribuição uniforme).
2. Qual é o p-valor? O que você conclui?
3. Se houver diferença, qual embalagem parece ser a preferida?
4. Que recomendações você faria para o supermercado?

Exercício 3: Tratamento Médico

Contexto

Um estudo clínico avaliou a eficácia de três tratamentos diferentes (A, B, C) para uma doença. Os pacientes foram classificados como ”Curados” ou ”Não Curados” após o tratamento.

Dados

```
# Tabela de contingência
tratamento <- c("A", "A", "B", "B", "C", "C")
resultado <- c("Curado", "Nao Curado", "Curado", "Nao Curado",
"Curado", "Nao Curado")
contagem <- c(30, 20, 40, 10, 25, 25)

# Criar tabela com os dados agregados
dados <- data.frame(tratamento, resultado, contagem)
```

Perguntas

1. Existe associação entre o tipo de tratamento e a cura?
2. Qual tratamento apresenta a maior taxa de cura?
3. Calcule as porcentagens de cura por tratamento.
4. Se um novo paciente chegar, qual tratamento você recomendaria? Por quê?